

Совместное адаптивное спекулятивное декодирование

БОЛЬШИХ ЯЗЫКОВЫХ МОДЕЛЕЙ

на основе марковского процесса принятия решений (JointAdaSpec)

Выпускная квалификационная работа (магистерская диссертация)

Козин Александр Александрович

Научный руководитель: _____

Кубанский государственный университет • факультет прикладной математики


кафедра математического моделирования • Краснодар, 2026

Актуальность и проблема

- Стоимость LLM сместилась на инференс — 60–90 % полной стоимости жизненного цикла модели.
- Авторегрессионная генерация: n последовательных непараллелизуемых проходов; режим, ограниченный памятью.
- Спекулятивное декодирование (SD) — промышленный стандарт ускорения (vLLM, TensorRT-LLM).
- **Проблема: длина черновика γ и порог верификации T фиксированы и неадаптивны.**

Спекулятивное декодирование: идея и две оси

- Дешёвая черновая модель предлагает блок токенов; дорогая целевая проверяет его за один проход.
- Modified rejection sampling гарантирует точное распределение — без потерь качества при $T = 1$.
- Две независимые оси управления: длина черновика γ и порог верификации T .



Две «ручки» управления: γ — сколько токенов предлагать · T — насколько строго принимать

Сравнение методов и исследовательский пробел

	Длина: фиксир.	Длина: эвристич.	Длина: обучаемая
Вериф.: строгая	классич. SD	DISCO	SpecDec++, SVIP
Вериф.: ослабл. фикс.	AutoJudge, Fuzzy SD	—	—
Вериф.: ослабл. адаптивн.	MARS	—	JointAdaSpec ★

Существующие методы адаптируют ровно одну ось. Пустая клетка «**обучаемая длина × адаптивная верификация**» — её закрывает JointAdaSpec.

Цель и задачи

Цель: метод адаптивного спекулятивного декодирования, совместно управляющий парой (длина черновика, порог верификации) как задачей оптимального управления.

1. Анализ методов ускорения инференса и точная формулировка исследовательского пробела.
2. MDP-модель совместного управления и её теоретический анализ.
3. Воспроизводимый программный комплекс.
4. Экспериментальная оценка и установление границ применимости.

Метод JointAdaSpec

- Каждый цикл декодирования = выбор действия в дискретном MDP (S, A, P, r, λ).
- Состояние $s = (\text{энтропия черновика } H, \text{ дивергенция } K = KL(q||p), \text{ позиция } k)$.
- Действие $a = (\text{длина } \in \{\text{stop}, \text{continue}\}, \text{ порог } T \text{ из 8 уровней})$; $|S| = 3600, |A| = 16$.
- Награда $r = \eta - k \cdot D$: скорость минус штраф за качество; решение — value iteration, $\lambda = 0,99$.
- Политика — таблица ≈ 2 КБ, поиск $O(1)$ на шаг, без обучения нейросетей.



Теоретические результаты

Теорема А. Выборочная сложность оценщика переходов

Теорема В. Беллман-инвариантность аддитивного штрафа качества


Теорема С. Оценка субоптимальности каскада через массу нарушения $\mu^*_J(B)$

Теорема D. Точный разрыв ценности совместной и каскадной политик

Теорема 2.3. Слабое доминирование совместной политики над каскадной

Теорема 2.4. Скаляризация Парето-фронта по коэффициенту k

Программная реализация и воспроизводимость



- стек: Python 3.12, PyTorch, scipy.sparse, Hydra; ядро покрыто 72 модульными тестами.
- Воспроизводимость: манифесты (git SHA, сиды [42, 43, 44], SHA256), детерминированные прогоны.
- Совместимость с инференс-фреймворками без переобучения базовых моделей.


Результаты: пара 14B / 0.5B

Метод	ЕМ, %	ток/с	Δ ЕМ к target	p
target_only	52,93	14,45	—	—
speculative	53,27	4,88	+0,33	0,877
cascade	57,13	10,29		
jointadaspec	57,00	10,84		

+4,07 п.п.

ЕМ к прямой генерации (p = 0,0205)


2,22× пропускной способности (к ванильному SD)



Парето-фронт: прямая генерация (target_only) — самая быстрая точка.

Адаптивность нетривиальна: теорема E


Theorem E — joint dominates fixed fuzzy_sd on quality AND speed (14B/0.5B, n=300)



JointAdaSpec точнее любого фиксированного T на **+4...+8 п.п.** EM и быстрее **≈ 3,7×** (11,12 против ≈ 3,0 ток/с).

Честная картина результатов

- joint $\approx$ cascade — статистическая ничья ($\Delta = -0,13 \%$, $p = 0,96$), ровно как предсказывает теорема D.
- Прямая генерация (AR) — самый быстрый метод; «2,22 $\times$ » — относительно ванильного SD, не AR.
- Пара 7B / 1.5B (4,7 $\times$) — нуль-результат, устойчивый по триангуляции на трёх независимых окнах.
- Прирост качества немонотонен: +7,4 п.п. при умеренной доле принятий, -2,6 п.п. при высокой.



к-развёртка: joint $\approx$ cascade на всём диапазоне.

Это не слабость изложения, а строгая характеристика области применимости.

Заключение и вклад

Вклад 1

Единый MDP-фреймворк совместного управления (длина, порог) — первый в литературе.

Вклад 2

Теоретический аппарат A / B / C / D / 2.3 / 2.4 с доказательствами.

Вклад 3

Честная эмпирическая характеристика: где адаптивность помогает, где нет и почему joint сводится к каскаду.

Направления: древовидное обобщение, распределительные признаки состояния, GPU-резидентная политика.

Положения, выносимые на защиту

1. Совместное управление (длина, порог) формализуемо как конечный MDP (≈ 3600 состояний), решаемый точно методом value iteration без обучения нейросетевых модулей.
2. Доказаны выборочная сложность (A), Беллман-инвариантность штрафа (B), оценка и точный разрыв совместной и каскадной политик (C, D), слабое доминирование (2.3) и Парето-скаляризация (2.4).
3. Адаптивное управление значимо превосходит все неадаптивные базисы: +4,07 п.п. EM на 14B/0.5B ($p = 0,0205$) и +4...+8 п.п. над фиксированным порогом при $\approx 3,7\times$ скорости.
4. Установлены границы применимости: метод сводится к каскадной политике (теорема D) и не даёт выигрыша при низком отношении мощностей моделей.

Спасибо за внимание

Готов ответить на ваши вопросы.

Репозиторий: код, 72 теста, манифесты воспроизводимости,
полный текст ВКР и план презентации.

github.com/levvius/adaptive-speculative-decoding



→ репозиторий