

# Оптимизация больших языковых моделей методом адаптивного спекулятивного декодирования

Метод JointAdaSpec на основе марковского процесса принятия решений

Выпускная квалификационная работа (магистерская диссертация)

Козин Александр Александрович

Научный руководитель: \_\_\_\_\_

Кубанский государственный университет • факультет прикладной математики

кафедра математического моделирования • Краснодар, 2026


# Актуальность и проблема

---

- Стоимость LLM сместилась на инференс — 60–90 % полной стоимости жизненного цикла модели.
- Авторегрессионная генерация:  $n$  последовательных непараллелизуемых проходов; режим, ограниченный памятью.
- Спекулятивное декодирование (SD) — промышленный стандарт ускорения (vLLM, TensorRT-LLM).
- **Проблема: длина черновика  $\gamma$  и порог верификации  $T$  фиксированы и неадаптивны.**

# Спекулятивное декодирование: идея и две оси

- Дешёвая черновая модель предлагает блок токенов; дорогая целевая проверяет его за один проход.
- Modified rejection sampling гарантирует точное распределение — без потерь качества при  $T = 1$ .
- Две независимые оси управления: длина черновика  $\gamma$  и порог верификации  $T$ .



Две «ручки» управления:  $\gamma$  — сколько токенов предлагать ·  $T$  — насколько строго принимать

# Сравнение методов и исследовательский пробел

|                           | Длина: фиксир.      | Длина: эвристич. | Длина: обучаемая |
|---------------------------|---------------------|------------------|------------------|
| Вериф.: строгая           | классич. SD         | DISCO            | SpecDec++, SVIP  |
| Вериф.: ослабл. фикс.     | AutoJudge, Fuzzy SD | —                | —                |
| Вериф.: ослабл. адаптивн. | MARS                | —                | JointAdaSpec ★   |

Существующие методы адаптируют ровно одну ось. Пустая клетка «**обучаемая длина × адаптивная верификация**» — её закрывает JointAdaSpec.

# Цель и задачи

---

**Цель:** метод адаптивного спекулятивного декодирования, совместно управляющий парой (длина черновика, порог верификации) как задачей оптимального управления.

1. Анализ методов ускорения инференса и точная формулировка исследовательского пробела.
2. MDP-модель совместного управления и её теоретический анализ.
3. Воспроизводимый программный комплекс.
4. Экспериментальная оценка и установление границ применимости.

# Метод JointAdaSpec

- Каждый цикл декодирования = выбор действия в дискретном MDP ( $S, A, P, r, \lambda$ ).
- Состояние  $s = (\text{энтропия черновика } H, \text{ дивергенция } K = KL(q||p), \text{ позиция } k)$ .
- Действие  $a = (\text{длина } \in \{\text{stop}, \text{continue}\}, \text{ порог } T \text{ из 8 уровней}); |S| = 3600, |A| = 16$ .
- Награда  $r = \eta - k \cdot D$ : скорость минус штраф за качество; решение — value iteration,  $\lambda = 0,99$ .
- **Политика — таблица  $\approx 2$  КБ, поиск  $O(1)$  на шаг, без обучения нейросетей.**



# Теоретические результаты

**Теорема А.** Выборочная сложность оценщика переходов

**Теорема В.** Беллман-инвариантность аддитивного штрафа качества


**Теорема С.** Оценка субоптимальности каскада через массу нарушения  $\mu^*_J(B)$

**Теорема D.** Точный разрыв ценности совместной и каскадной политик

**Теорема 2.3.** Слабое доминирование совместной политики над каскадной

**Теорема 2.4.** Скаляризация Парето-фронта по коэффициенту  $k$

# Программная реализация и воспроизводимость



- стек: Python 3.12, PyTorch, scipy.sparse, Hydra; ядро покрыто 72 модульными тестами.
- Воспроизводимость: манифесты (git SHA, сиды [42, 43, 44], SHA256), детерминированные прогоны.
- Совместимость с инференс-фреймворками без переобучения базовых моделей.




# Результаты: пара 14B / 0.5B

| Метод        | ЕМ, % | ток/с | Δ ЕМ к target | p     |
|--------------|-------|-------|---------------|-------|
| target_only  | 52,93 | 14,45 | —             | —     |
| speculative  | 53,27 | 4,88  | +0,33         | 0,877 |
| cascade      | 57,13 | 10,29 |               |       |
| jointadaspec | 57,00 | 10,84 |               |       |

+4,07 п.п.

ЕМ к прямой генерации (p = 0,0205)


2,22× пропускной способности (к ванильному SD)



Парето-фронт: прямая генерация (target\_only) — самая быстрая точка.

# Адаптивность нетривиальна: теорема E


Theorem E — joint dominates fixed fuzzy\_sd on quality AND speed (14B/0.5B, n=300)



JointAdaSpec точнее любого фиксированного T на **+4...+8 п.п.** EM и быстрее **≈ 3,7×** (11,12 против ≈ 3,0 ток/с).

# Честная картина результатов

- joint  $\approx$  cascade — статистическая ничья ( $\Delta = -0,13\%$ ,  $p = 0,96$ ), ровно как предсказывает теорема D.
- Прямая генерация (AR) — самый быстрый метод; «2,22 $\times$ » — относительно ванильного SD, не AR.
- Пара 7B / 1.5B (4,7 $\times$ ) — нуль-результат, устойчивый по триангуляции на трёх независимых окнах.
- Прирост качества немонотонен: +7,4 п.п. при умеренной доле принятий, -2,6 п.п. при высокой.



к-развёртка: joint  $\approx$  cascade на всём диапазоне.

Это не слабость изложения, а строгая характеристика области применимости.

# Заключение и вклад

---

## Вклад 1

Единый MDP-фреймворк совместного управления (длина, порог) — первый в литературе.

## Вклад 2

Теоретический аппарат A / B / C / D / 2.3 / 2.4 с доказательствами.

## Вклад 3

Честная эмпирическая характеристика: где адаптивность помогает, где нет и почему joint сводится к каскаду.

**Направления:** древовидное обобщение, распределительные признаки состояния, GPU-резидентная политика.

# Положения, выносимые на защиту

---

1. Совместное управление (длина, порог) формализуемо как конечный MDP ( $\approx 3600$  состояний), решаемый точно методом value iteration без обучения нейросетевых модулей.
2. Доказаны выборочная сложность (A), Беллман-инвариантность штрафа (B), оценка и точный разрыв совместной и каскадной политик (C, D), слабое доминирование (2.3) и Парето-скаляризация (2.4).
3. Адаптивное управление значимо превосходит все неадаптивные базисы: +4,07 п.п. EM на 14B/0.5B ( $p = 0,0205$ ) и +4...+8 п.п. над фиксированным порогом при  $\approx 3,7\times$  скорости.
4. Установлены границы применимости: метод сводится к каскадной политике (теорема D) и не даёт выигрыша при низком отношении мощностей моделей.

# Спасибо за внимание

Готов ответить на ваши вопросы.

Репозиторий: код, 72 теста, манифесты воспроизводимости,  
полный текст ВКР и план презентации.

[github.com/levvius/adaptive-speculative-decoding](https://github.com/levvius/adaptive-speculative-decoding)



→ репозиторий