

JointAdaSpec

Оптимизация больших языковых моделей методом адаптивного спекулятивного декодирования

Метод JointAdaSpec на основе марковского
процесса принятия решений

Выпускная квалификационная работа

Козин А.А.

Научный руководитель — Калайдина Г.В.

Центр искусственного интеллекта КубГУ

Кафедра анализа данных и искусственного интеллекта

Краснодар, 2026

Актуальность и проблема

- Стоимость LLM сместилась на **инференс** — это 60–90% полной стоимости модели за жизненный цикл.
- Авторегрессионная генерация — **n последовательных**, непараллелизуемых проходов; режим, ограниченный памятью (memory-bound).
- Спекулятивное декодирование (SD) — промышленный **стандарт** ускорения: vLLM, TensorRT-LLM.
- Проблема: длина черновика **γ** и порог верификации **T** заданы **фиксированными** и неадаптивны.

60–90%

полной стоимости LLM
приходится на
инференс

Спекулятивное декодирование: идея и две оси



Черновая модель — дешёвая
предлагает блок из γ токенов вперёд



Целевая модель — дорогая
проверяет весь блок за **один** проход



Принятый префикс + ресемпл
modified rejection sampling

ДВЕ ОСИ УПРАВЛЕНИЯ



Длина черновика
сколько токенов предлагать



Порог верификации
насколько строго принимать

При $T = 1$ — генерация **без потерь** качества (lossless).

Сравнение методов и исследовательский пробел

→ Управление длиной черновика γ

Адаптивность верификации $T \downarrow$	Фиксированная	Эвристическая	Обучаемая
Строгая	SD (классич.)	DISCO	SpecDec++ · SVIP
Ослабленная, фикс. порог	AutoJudge · Fuzzy SD	—	—
Ослабленная, адаптивная	MARS	—	★ JointAdaSpec настоящая работа

Существующие методы адаптируют ровно одну ось при фиксированной другой.
Пустую клетку «обучаемая длина × адаптивная верификация» закрывает JointAdaSpec.

Цель и задачи

ЦЕЛЬ

Метод адаптивного SD, совместно управляющий парой (длина, порог) как задачей оптимального управления.

- 1 Анализ методов и точная формулировка **пробела**.
- 2 MDP-модель совместного управления и её **теоретический анализ**.
- 3 Воспроизводимый **программный комплекс**.
- 4 Экспериментальная оценка и **границы применимости**.

Обозначения и формулы

H	энтропия черного распределения q	K	KL-дивергенция $KL(q p)$ — «расхождение» черного и цели
i	позиция токена внутри блока	Y	длина черного — сколько токенов предлагать
T	порог верификации — строгость приёмки (8 уровней)	κ	коэффициент штрафа за потерю качества
λ	коэффициент дисконтирования (0,99)	η	мгновенная скорость (токены за проход)
D	мера потери качества (штрафуемая)	p, q	целевое и черновое распределения
μ_j(B)	стационарная масса нарушения (теор. C/D)	EM	exact-match — доля точных ответов (GSM8K)


СОСТОЯНИЕ · **s**
 $s = (H, K, i)$

ДЕЙСТВИЕ · **a**
 $a = (\text{длина}, T)$
длина ∈ {stop, continue} · T из 8 уровней

НАГРАДА · **r**
 $r = \eta - \kappa \cdot D$
скорость η минус штраф за качество κ·D

РЕШЕНИЕ
value iteration, λ = 0,99
уравнение Беллмана · |S| = 3600 · |A| = 16

Метод JointAdaSpec



НАГРАДА $r = \eta - \kappa \cdot D$ скорость – штраф за качество

- $|S| = 3600$
- $|A| = 16$
- $\lambda = 0,99$
- политика ≈ 2 КБ
- поиск 0(1) / шаг
- решается за секунды

Теоретические результаты

A

Выборочная сложность оценщика переходов — гарантия обучения из трейсов.

B

Беллман-инвариантность **аддитивного** штрафа качества (мультипликативный её ломал).

C

Оценка субоптимальности каскада через массу нарушения $\mu^*_J(B)$.

D • ключевая

Точный разрыв ценности совместной и каскадной политик — объясняет, почему на практике joint = cascade.

2.3

Слабое доминирование совместной политики.

2.4

Скаляризация Парето по коэффициенту κ .

Реализация и воспроизводимость

КОНВЕЙЕР ИЗ 4 СТАДИЙ



- АППАРАТУРА
- NVIDIA RTX 5090 · 32 ГБ · один GPU, однопроцессно
- ДЛИТЕЛЬНОСТЬ
- решение MDP — **секунды** (value iteration); сбор трейсов и бенчмарк — ≈ 14–18 ч на одном GPU
- СТЕК
- Python 3.12 · PyTorch · scipy.sparse · Hydra
- ТЕСТЫ · МАНИФЕСТЫ
- 72** теста ядра · git SHA · сиды [42, 43, 44] · SHA-256
- ГАРАНТИИ
- полный детерминизм прогонов; без переобучения базовых моделей

Результаты: пара 14B / 0.5B

МЕТОД	EM, %	TOK/C	Δ EM	P
target_only	52,93	14,45	—	—
speculative	53,27	4,88	+0,33	0,877
cascade	57,13	10,29	+4,20	0,015
jointadaspec	57,00	10,84	+4,07	0,020

+4,07п.п.

ЕМ к прямой генерации ·
p = 0,0205

2,22×

к ванильному
спекулятивному
декодированию




Рис. 4.1 — Парето-фронт. target_only — самая быстрая точка; joint и cascade рядом по качеству.

Адаптивность нетривиальна (теорема E)




Рис. 4.3 — JointAdaSpec против фиксированного порога fuzzy_sd: качество (слева) и скорость (справа).

+4...8 п.п.

ЕМ против **любого**
фиксированного порога
T

≈ 3,7 ×

быстрее: 11,12 против ≈
3,0 ток/с

Совместная политика
доминирует неадаптивный
базис **сразу по обеим осям.**

Честная картина результатов

- joint $\approx$ cascade — статистическая **ничья** ($\Delta = -0,13\%$, $p = 0,96$), ровно как предсказывает теорема D.
- Прямая генерация (AR) — **самый быстрый** метод; «2,22×» — относительно ванильного SD, не AR.
- Пара 7B/1.5B (4,7×) — **нуль-результат**, устойчивый по триангуляции на 3 независимых окнах.
- Прирост качества **немонотонен**: +7,4 п.п. при умеренной доле принятий, −2,6 при высокой.




Рис. 4.4 — κ-развёртка на 7B/1.5B: joint и cascade неразличимы по всему диапазону.

Это не слабость изложения, а **строгая характеристика** области применимости.

Заключение и вклад

01

Единый MDP-фреймворк

совместного управления (длина, порог)
— первый в литературе.

02

Теоретический аппарат

шесть результатов A / B / C / D / 2.3 / 2.4 с
доказательствами.

03

Честная характеристика

где адаптивность помогает, где нет и
почему joint сводится к каскаду.

НАПРАВЛЕНИЯ РАЗВИТИЯ

древовидное обобщение

распределительные признаки состояния

GPU-резидентная политика

Положения, выносимые на защиту

- 1 Совместное управление (длина, порог) **формализуемо как конечный MDP** (~3600 состояний), решаемый точно value iteration без обучения нейросетей.
- 2 Доказаны **теоретические свойства**: выборочная сложность, Беллман-инвариантность, оценка и точный разрыв с каскадом, слабое доминирование, Парето-скаляризация.
- 3 Метод **значимо превосходит** все неадаптивные базисы: +4,07 п.п. EM на 14B/0.5B ($p = 0,0205$) и +4...8 п.п. над фикс. порогом при $\approx 3,7\times$ скорости.
- 4 Установлены **границы применимости**: метод сводится к каскадной политике (теорема D) и не даёт выигрыша при низком отношении мощностей.

— ОТКРЫТЫЙ РЕПОЗИТОРИЙ

Спасибо за внимание

Готов ответить на вопросы.

`github.com/levvius/adaptive-speculative-decoding`

Реализация метода · 72 модульных теста ·
манифесты воспроизводимости

